

FUNDAÇÃO OSWALDO CRUZ — FIOCRUZ

Vice-Presidência de Pesquisa e Coleções Biológicas (VPPCB)

Instituto Aggeu Magalhães — Fiocruz Pernambuco

Projeto de Pesquisa — vinculado ao Edital de Pós-Doutorado Júnior (PDJ) 2026

PROJETO DE PESQUISA DO(A) SUPERVISOR(A)

GenVig-IA — Vigilância Genômica Integrada e Inteligência Computacional para Caracterização Molecular e Predição de Risco de Vírus Emergentes e Zoonóticos de Importância em Saúde Pública no Brasil

Coordenador(a) / Supervisor(a)	Marcelo Henrique Santos Paiva
Unidade	Instituto Aggeu Magalhães (IAM) — Fiocruz Pernambuco
Laboratório / Núcleo	Laboratório de Entomologia
Grande área	Ciências Biológicas / Bioinformática / Saúde Coletiva
Linha de pesquisa	Entomologia, vigilância de vetores e IA aplicada à saúde
Subprojeto PDJ vinculado	JEPA-Spillover — candidato Gabriel Bezerra Motta Câmara
Duração	36 meses (subprojeto PDJ: 12 meses, renovável)

Documento de trabalho, redigido como projeto guarda-chuva plausível para contextualizar o subprojeto de PDJ. Ajustar nomes, titulação e dados institucionais (campos entre []) antes da submissão.

1. Resumo

As doenças infecciosas emergentes e reemergentes — em especial as de origem viral e potencial zoonótico — representam uma ameaça crescente à saúde pública global e brasileira, como evidenciado pelas epidemias de Zika e chikungunya no Nordeste, pela emergência do Oropouche e pela pandemia de COVID-19. O barateamento do sequenciamento de nova geração (NGS) e a expansão das redes de vigilância genômica produziram um volume sem precedentes de genomas virais, mas a capacidade de análise, integração e, sobretudo, de predição de risco não acompanhou esse crescimento. Este projeto propõe uma plataforma integrada de bioinformática e inteligência computacional para caracterização molecular, monitoramento filodinâmico e predição de risco de vírus de importância em saúde pública, articulando dados genômicos, de hospedeiros e ecológicos. O projeto organiza-se em quatro eixos — (i) aquisição e curadoria de dados, (ii) caracterização molecular e filogenética/filodinâmica, (iii) modelagem computacional e aprendizado de máquina para predição de risco zoonótico e (iv) integração com a vigilância e disseminação. O eixo (iii) é desenvolvido, no âmbito do Pós-Doutorado Júnior, pelo subprojeto JEPA-Spillover, que aplica redes de arquitetura preditiva em espaço latente (JEPA) para priorizar vírus com maior potencial de transbordamento antes da ocorrência de surtos. Espera-se entregar uma infraestrutura analítica aberta e reprodutível, com impacto direto para a capacidade de resposta do Sistema Único de Saúde (SUS).

2. Introdução e justificativa

2.1. Relevância científica

Estima-se que a maioria das doenças infecciosas emergentes em humanos tenha origem zoonótica, e que exista um vasto 'espaço viral' ainda não caracterizado em reservatórios animais. A vigilância genômica tornou-se ferramenta central para detectar e caracterizar esses agentes, mas enfrenta dois gargalos científicos. Primeiro, a análise filogenética e filodinâmica clássica descreve o passado da transmissão, porém tem poder limitado para antecipar quais vírus, entre os milhares recém-descritos por metagenômica, têm maior probabilidade de infectar humanos. Segundo, os métodos supervisionados de predição de risco dependem de rótulos de zoonose escassos e enviesados — a ausência de registro de infecção humana frequentemente reflete falta de estudo, e não ausência de risco. Há, portanto, uma lacuna metodológica clara: são necessárias abordagens capazes de aprender, de forma pouco supervisionada, representações funcionais dos genomas virais que capturem compatibilidade com hospedeiros. Avanços recentes em aprendizado auto-supervisionado — em particular as arquiteturas preditivas em espaço latente (JEPA) — abrem uma via promissora e ainda inexplorada nesse domínio.

2.2. Relevância para o SUS e para a sociedade

O Brasil convive com uma carga elevada e recorrente de arboviroses (dengue, Zika, chikungunya, Oropouche, febre amarela) e com o risco permanente de introdução e emergência de novos patógenos. O Nordeste, região de atuação do Instituto Aggeu Magalhães, foi o epicentro da epidemia de Zika e da síndrome congênita associada, expondo a necessidade de capacidade local de resposta rápida. Este projeto contribui diretamente para o SUS ao fortalecer a vigilância genômica regional, gerar conhecimento acionável sobre patógenos circulantes e desenvolver uma camada de inteligência preditiva que amplia a janela de antecipação a surtos. A proposta é explicitamente complementar — e não concorrente — a sistemas consolidados de monitoramento em tempo real,

como o InfoDengue e o InfoGripe, atuando na etapa anterior de priorização de ameaças ainda não caracterizadas. Ao produzir ferramentas abertas, reprodutíveis e adaptadas ao contexto nacional, o projeto reforça a soberania tecnológica em saúde e a formação de recursos humanos qualificados, alinhando-se à missão institucional da Fiocruz e às diretrizes de fortalecimento da vigilância genômica pós-COVID-19.

3. Objetivos

3.1. Objetivo geral

Desenvolver e consolidar uma plataforma integrada de bioinformática e inteligência computacional para caracterização molecular, monitoramento e predição de risco de vírus emergentes e zoonóticos de importância em saúde pública, com aplicação ao contexto brasileiro e integração às redes de vigilância do SUS.

3.2. Objetivos específicos

- Estruturar um fluxo automatizado de aquisição e curadoria de genomas virais e metadados de hospedeiro, taxonomia e ecologia a partir de bases públicas e de redes de vigilância.
- Caracterizar molecularmente e reconstruir a filogenia e a filodinâmica de vírus prioritários circulantes no Brasil, com ênfase em arbovírus e vírus respiratórios.
- (*) Desenvolver métodos de aprendizado de máquina auto-supervisionado (redes JEPA) para aprender representações latentes de genomas virais e priorizar vírus com potencial de transbordamento zoonótico.
- Integrar os resultados de priorização à vigilância genômica e epidemiológica, propondo mecanismos de articulação com sistemas como InfoDengue/InfoGripe.
- Formar recursos humanos e disponibilizar código, modelos e documentação de forma aberta e reprodutível, fortalecendo a capacidade analítica institucional.

() Objetivo específico desenvolvido, no âmbito do Pós-Doutorado Júnior, pelo subprojeto JEPA-Spillover (candidato Gabriel Bezerra Motta Câmara).*

4. Desenho e abordagem teórico-metodológica

O projeto adota um desenho modular em quatro eixos interdependentes, combinando bioinformática genômica clássica, epidemiologia molecular e aprendizado de máquina. A abordagem prioriza reprodutibilidade (fluxos versionados, ambientes declarados, seeds fixas) e ciência aberta.

Eixo 1 — Aquisição e curadoria de dados

Coleta automatizada de sequências e metadados de bases públicas (NCBI Vírus/Entrez, BV-BRC/ViPR, VirusHostDB, NCBI Taxonomy, ICTV) e de dados de acesso controlado (GISAID: EpiCoV, EpiArbo, EpiNiV), mediante credenciamento institucional. Curadoria com controle de qualidade (comprimento, bases ambíguas), remoção de duplicatas, padronização taxonômica e integração de metadados de hospedeiro e interações vírus-hospedeiro (IntAct/EMBL-EBI).

Eixo 2 — Caracterização molecular, filogenia e filodinâmica

Montagem e anotação de genomas, alinhamentos, inferência filogenética (máxima verossimilhança e abordagens bayesianas) e análise filodinâmica para reconstruir introduções, dispersão e dinâmica

temporal de vírus prioritários, com ênfase em arbovírus e vírus respiratórios circulantes no Brasil. Uso de fluxos padronizados do tipo Nextstrain para visualização e compartilhamento.

Eixo 3 — Modelagem computacional e IA (subprojeto JEPA-Spillover)

Desenvolvimento de representações genômicas (k-mers, embeddings) e de uma arquitetura JEPA genômica que aprende, sem reconstrução literal de nucleotídeos e com baixa dependência de rótulos, a prever embeddings de regiões mascaradas do genoma. Extensão vírus-hospedeiro para aprender compatibilidades latentes (incluindo Homo sapiens) e fine-tuning supervisionado para risco de spillover, validado com particionamento estratificado por família e holdout de famílias inteiras. Geração de um ranking de vírus prioritários combinando proximidade latente a zoonóticos conhecidos e probabilidade supervisionada. Este eixo constitui o subprojeto de PDJ.

Eixo 4 — Integração com a vigilância e disseminação

Tradução dos resultados para uso em vigilância: painéis interativos, rankings de priorização e proposta de mecanismos de integração com sistemas de monitoramento (InfoDengue/InfoGripe) e redes genômicas da Fiocruz. Disseminação via repositórios públicos, manuscritos, material didático e capacitação de equipes.

5. Articulação com o subprojeto JEPA-Spillover

O subprojeto de Pós-Doutorado Júnior JEPA-Spillover materializa o Eixo 3 deste projeto. Enquanto o projeto guarda-chuva provê o contexto biológico, os dados curados (Eixo 1) e a caracterização molecular/filodinâmica (Eixo 2), o subprojeto aporta a inovação metodológica em inteligência artificial: a primeira aplicação, ao domínio de vigilância genômica de vírus de RNA, das arquiteturas preditivas em espaço latente (JEPA). A expertise do candidato em aprendizado de máquina e desenvolvimento de software reprodutível complementa diretamente a competência do Laboratório de Entomologia em entomologia e epidemiologia de doenças transmitidas por vetores, criando sinergia com potencial de publicações conjuntas, captação de novos financiamentos e consolidação de uma linha de pesquisa em IA aplicada à saúde no IAM. Os produtos do subprojeto (embeddings, modelos, rankings) retroalimentam os Eixos 2 e 4, fechando o ciclo entre caracterização, predição e vigilância.

6. Resultados esperados e impacto

- Banco integrado, curado e documentado de genomas virais e metadados, reutilizável pela instituição.
- Caracterização molecular e filodinâmica de vírus prioritários circulantes no Brasil.
- Modelo JEPA genômico e classificador de risco de spillover, com ranking de vírus prioritários para vigilância.
- Plataforma/painel aberto e reprodutível, com proposta de integração à vigilância (InfoDengue/InfoGripe).
- Publicações científicas, material didático em português e capacitação de recursos humanos em IA aplicada à saúde.
- Fortalecimento da capacidade analítica e da competitividade do IAM/Fiocruz em editais nacionais e internacionais.

7. Infraestrutura disponível

[Descrever a infraestrutura do Laboratório de Entomologia/grupo/IAM: instalações, equipamentos, recursos computacionais (GPU/HPC), bases de dados e apoio institucional — a preencher.]

8. Cronograma (36 meses)

Fase	Atividades	Período	Eixo
1	Estruturação do fluxo de dados; curadoria e banco integrado	Meses 1-6	1
2	Caracterização molecular, filogenia e filodinâmica de vírus prioritários	Meses 4-18	2
3	Representações, JEPA genômica e extensão vírus-hospedeiro (PDJ)	Meses 7-18	3
4	Fine-tuning de risco, validação e ranking de priorização (PDJ)	Meses 13-24	3
5	Integração com vigilância; painéis e proposta de articulação	Meses 19-30	4
6	Disseminação: manuscritos, material didático, capacitação, relatório	Meses 25-36	4

O subprojeto de Pós-Doutorado Júnior (JEPA-Spillover) concentra-se nas Fases 3 e 4 (Eixo 3), com vigência inicial de 12 meses, renovável, e é plenamente exequível dentro desse período — parte substancial da infraestrutura de software já se encontra implementada em fase de prova de conceito.

9. Equipe e colaborações

- **Supervisor:** Marcelo Henrique Santos Paiva — coordenação, entomologia e saúde pública / vigilância de vetores (IAM/Fiocruz).
- **Bolsista PDJ:** Gabriel Bezerra Motta Câmara — modelagem computacional e IA (subprojeto JEPA-Spillover).
- **Equipe:** [Demais membros do Laboratório de Entomologia e colaboradores do IAM].
- **Colaborações:** [Redes de vigilância genômica da Fiocruz; colaborações nacionais e internacionais].

10. Referências selecionadas

[1] LeCun, Y. A Path Towards Autonomous Machine Intelligence. Open Review, 2022.

[2] Assran, M. et al. Self-Supervised Learning from Images with a Joint-Embedding Predictive Architecture (I-JEPA). CVPR, 2023.

[3] Carroll, D. et al. The Global Virome Project. Science, 2018.

[4] Mollentze, N.; Streicker, D. G. et al. Identifying and prioritizing potential human-infecting viruses from their genome sequences. PLoS Biology, 2021.

[5] Hadfield, J. et al. Nextstrain: real-time tracking of pathogen evolution. Bioinformatics, 2018.

[6] Faria, N. R. et al. Genomic and epidemiological monitoring of arboviruses (Zika/dengue) in Brazil. Science, 2016/2017.

- [7] Codeço, C. T. et al. InfoDengue: sistema de alerta de arboviroses. Fiocruz.
- [8] Mihara, T. et al. Virus-Host Database (VHDB). Viruses, 2016.