

FUNDAÇÃO OSWALDO CRUZ — FIOCRUZ

Vice-Presidência de Pesquisa e Coleções Biológicas (VPPCB)

Instituto Aggeu Magalhães — Fiocruz Pernambuco

Edital de Pós-Doutorado Júnior (PDJ) — Vigência 2026–2027

SUBPROJETO DO CANDIDATO

JEPA-Spillover: aprendizado preditivo em espaço latente para vigilância genômica de vírus com potencial zoonótico

Candidato	Gabriel Bezerra Motta Câmara
Supervisor(a)	[Nome do(a) supervisor(a) — servidor(a) ativo(a) da Fiocruz]
Projeto do(a) supervisor(a)	GenVig-IA — Vigilância Genômica Integrada e Inteligência Computacional para vírus emergentes e zoonóticos (Eixo 3)
Unidade	Instituto Aggeu Magalhães (IAM) — Fiocruz Pernambuco
Laboratório / Grupo	[Nome do laboratório ou grupo de pesquisa]
Modalidade	Bolsa Nova
Vigência proposta	12 meses (mínimo do edital) — prorrogável conforme normas
Grande área	Ciências da Saúde / Bioinformática / Inteligência Artificial aplicada à Saúde
Linha de pesquisa	Vigilância genômica, saúde pública e predição de risco zoonótico

Recife — PE • 2026

Os campos entre colchetes [] devem ser preenchidos com os dados do(a) supervisor(a) e do laboratório antes da submissão no sistema Fomento à Pesquisa on-line.

1. Resumo

Eventos de transbordamento zoonótico (spillover) estão entre as maiores ameaças à saúde pública global, como evidenciado pela pandemia de COVID-19. O volume de genomas virais cresce rapidamente por vigilância genômica, metagenômica ambiental e estudos de viroma, mas a maioria dos vírus recém-identificados não possui rótulos confiáveis de risco zoonótico — o que limita fortemente os métodos supervisionados tradicionais. Este subprojeto desenvolve uma abordagem auto-supervisionada baseada em redes JEPA (Joint Embedding Predictive Architecture) para aprender representações latentes de genomas virais, hospedeiros e contextos ecológicos, com o objetivo de priorizar vírus com maior potencial de spillover antes da ocorrência de surtos. A proposta é complementar — não concorrente — aos sistemas nacionais de vigilância já consolidados (InfoDengue, InfoGripe, SIVEP-Gripe), oferecendo uma camada de inteligência genômica que amplia a janela de antecipação. Todo o pipeline é aberto, reproduzível e já parcialmente implementado, com resultados preliminares promissores de baselines e infraestrutura computacional funcional.

2. Introdução e justificativa

A predição proativa de risco zoonótico enfrenta limitações estruturais que a abordagem JEPA busca superar. Modelos supervisionados dependem de rótulos 'zoonótico/não-zoonótico' escassos, incompletos e enviesados — um vírus classificado como 'não-zoonótico' pode simplesmente não ter sido suficientemente estudado. Sistemas como o InfoDengue e o InfoGripe são altamente eficazes no monitoramento em tempo real de vírus já conhecidos e circulantes, mas não foram projetados para identificar vírus desconhecidos com potencial zoonótico antes de um surto, pois métodos estatísticos tradicionais dependem de dados históricos de transmissão — inexistentes para vírus emergentes recém-descobertos.

Métodos de aprendizado profundo baseados em reconstrução (autoencoders, modelos de linguagem nucleotídeo a nucleotídeo) gastam capacidade modelando ruído de sequência de baixo nível em vez de semântica funcional. A JEPA, ao contrário, prevê representações latentes — não nucleotídeos — capturando relações biológicas relevantes com maior eficiência e baixa dependência de rótulos, o que a torna especialmente adequada para vírus pouco caracterizados.

2.1. Por que JEPA?

Abordagem	Limitação no contexto de spillover
Supervisionada (rótulos zoonótico/não)	Rótulos escassos, incompletos e enviesados; 'não zoonótico' pode significar apenas 'não estudado'.
Generativa / reconstrução (autoencoders, MLM nucleotídeo a nucleotídeo)	Gasta capacidade modelando ruído de baixo nível em vez de semântica funcional.
JEPA (predição em espaço latente)	Aprende relações latentes entre partes dos dados sem reconstrução literal e com baixa dependência de rótulos — ideal para vírus pouco caracterizados.

A arquitetura JEPA, proposta por Yann LeCun (Meta AI / NYU) como princípio fundador dos 'modelos de mundo' (World Models), representa hoje a fronteira do aprendizado de máquina auto-supervisionado. Nos últimos anos, uma série de implementações estabeleceu recordes em benchmarks de aprendizado sem rótulos:

- **I-JEPA (Image, 2023):** primeira implementação pública; treinada sem rótulos, supera MAE e DINO v2 em classificação linear e few-shot no ImageNet ao prever representações latentes em vez de pixels.
- **V-JEPA (Video, 2024):** extensão para vídeo; aprende representações espaço-temporais e supera modelos de difusão em compreensão de ação com ordens de magnitude menos parâmetros, demonstrando escalabilidade para sequências.
- **MC-JEPA (Multimodal, 2023):** integra predição latente com aprendizado contrastivo multimodal — diretamente relevante para integrar sequências genômicas a metadados de hospedeiro e contexto epidemiológico.
- **JEPA hierárquicas (2024–2025):** aprendem representações em múltiplas escalas; para genômica, capturam simultaneamente motivos curtos (códon, sítios de ligação) e a estrutura global do genoma.

Três características são especialmente vantajosas para sequências virais: (i) predição no espaço latente, não no espaço de entrada, forçando entendimento funcional em vez de memorização de composição de bases e ruído de sequenciamento; (ii) codificador-alvo por média móvel exponencial (EMA, stop-gradient), que gera sinal de treino estável e progressivamente mais rico, análogo à emergência de representações biológicas por pressão seletiva gradual; e (iii) dispensa de pares negativos, difíceis de definir em dados genômicos.

O JEPA-Spillover é — até onde conhecemos — a primeira aplicação da arquitetura JEPA ao domínio de vigilância genômica de vírus de RNA. Trabalhos anteriores em genômica auto-supervisionada (DNABERT, Nucleotide Transformer, HyenaDNA) usam variantes de BERT mascarado ou modelos autoregressivos que operam no espaço de tokens. Este posicionamento na fronteira metodológica constitui diferencial concreto para captação de financiamento, colaborações internacionais e formação de recursos humanos especializados.

3. Articulação com o projeto do(a) supervisor(a)

Este subprojeto vincula-se diretamente ao projeto de pesquisa do(a) supervisor(a) “GenVig-IA — Vigilância Genômica Integrada e Inteligência Computacional para Caracterização Molecular e Predição de Risco de Vírus Emergentes e Zoonóticos de Importância em Saúde Pública no Brasil”, do qual constitui a componente de inteligência computacional (Eixo 3). Enquanto o projeto guarda-chuva abrange a aquisição e curadoria de dados genômicos (Eixo 1) e a caracterização molecular, filogenética e filodinâmica de vírus prioritários circulantes no Brasil (Eixo 2), o subprojeto aporta métodos de aprendizado de máquina de última geração (JEPA/Transformers) para priorização proativa de vírus com potencial zoonótico, agregando capacidade analítica reprodutível e escalável ao grupo. Os produtos do subprojeto (embeddings, modelos e rankings de risco) retroalimentam os eixos de caracterização e de integração com a vigilância (Eixo 4). A convergência entre a expertise biológica/epidemiológica do laboratório e a competência computacional do candidato cria sinergia com potencial de gerar publicações conjuntas, novos editais e colaborações.

4. Objetivo geral

Desenvolver uma abordagem baseada em redes JEPA para aprender representações latentes de genomas virais, hospedeiros e contextos ecológicos, apoiando a predição e a priorização de vírus

com potencial de spillover, de forma aberta, reprodutível e integrável às redes de vigilância em saúde pública do Brasil.

5. Objetivos específicos

- Coletar e curar genomas virais públicos e integrar metadados de hospedeiros, taxonomia e ecologia em um banco padronizado e documentado.
- Construir representações genômicas (k-mers e embeddings baseados em Transformer) e estabelecer baselines comparativos.
- Implementar e treinar a JEPA genômica (contexto → alvo latente) para gerar embeddings virais.
- Estender a arquitetura para o par vírus–hospedeiro e, de forma exploratória, integrar contexto ecológico em um espaço latente compartilhado.
- Realizar fine-tuning supervisionado para risco de spillover e validar com particionamento estratificado por família e holdout de famílias inteiras.
- Aplicar interpretabilidade (SHAP), ablação e visualização (UMAP/t-SNE); produzir um ranking de vírus prioritários para vigilância.
- Disponibilizar código, modelos e documentação em repositório público reprodutível e promover capacitação da equipe.

6. Abordagem teórico-metodológica e métodos

6.1. Fontes de dados e curadoria

Scripts automatizados baixam sequências de bases públicas — NCBI Virus (via Entrez/Biopython), VirusHostDB (relações vírus–hospedeiro), NCBI Taxonomy (padronização), IntAct/VirHostNet (interações moleculares) e GISAID (credencial institucional; não redistribuído). A curadoria aplica controle de qualidade (comprimento mínimo, fração de bases ambíguas), remoção de duplicatas e padronização taxonômica, resultando em um dataset em formato Parquet com sequência, metadados de hospedeiro, taxonomia e rótulos de risco.

6.2. Representações e baselines

- **k-mer + PCA:** frequências de k-mers reduzidas por PCA (baseline rápido, sem GPU).
- **Transformer:** embeddings por codificadores de DNA pré-treinados (ex.: Nucleotide Transformer).
- **Baselines:** k-mers + Regressão Logística/Random Forest, LSTM supervisionada e Transformer supervisionado.

6.3. Arquitetura JEPA genômica

- **Codificador de contexto $f(\theta)$ (Transformer):** codifica um bloco observado do genoma.
- **Codificador-alvo por EMA:** gera o embedding de blocos mascarados (stop-gradient).
- **Preditor $g(\varphi)$:** prevê o embedding-alvo a partir do contexto + posição.

A perda é calculada no espaço latente (Smooth L1), não sobre nucleotídeos, incentivando o aprendizado de relações funcionais entre regiões do genoma.

6.4. Extensão vírus–hospedeiro e fine-tuning

O embedding viral passa a prever o embedding do hospedeiro associado, aprendendo compatibilidades latentes vírus–hospedeiro (incluindo Homo sapiens); uma versão exploratória integra embeddings ecológicos. Em seguida, os embeddings JEPA alimentam um classificador leve

treinado com rótulos derivados de histórico de infecção humana, amplitude de hospedeiros, surtos e transmissão interespécies.

6.5. Avaliação, interpretabilidade e ranking

- **Métricas:** AUROC, AUPRC, F1, precisão, recall, especificidade e Brier.
- **Validação:** validação cruzada estratificada por família (5 folds) + holdout de famílias inteiras para simular vírus emergentes.
- **Interpretabilidade:** SHAP + ablação (contribuição de regiões genômicas e variáveis) e projeções UMAP/t-SNE por família, hospedeiro e risco.
- **Ranking:** score de prioridade combinando proximidade latente a zoonóticos conhecidos e probabilidade supervisionada — vírus próximos a Ebola/SARS sobem no ranking automaticamente.

7. Atividades e metas

As metas abaixo articulam-se diretamente aos objetivos específicos (Seção 5) e às atividades do cronograma (Seção 8), garantindo coerência entre objetivos, atividades e produtos esperados.

Meta	Atividades	Entregável principal
1 — Base integrada	Levantamento de bases, coleta, QC, dedup e padronização taxonômica	Banco tabular/relacional + documentação de curadoria
2 — Representações + baselines	k-mers, embeddings e implementação de baselines	Scripts de pré-processamento, matriz de atributos, baselines
3 — JEPA genômica	Implementação, treinamento e avaliação de embeddings	Modelo funcional + checkpoints + avaliação de embeddings
4 — Extensão vírus-hospedeiro	Modelo vírus-hospedeiro + integração ecológica exploratória	Modelo JEPA vírus-hospedeiro + espaço latente compartilhado
5 — Fine-tuning + validação	Classificador de risco, validação, comparação e ranking	Métricas, comparação e ranking preliminar de vírus prioritários
6 — Disseminação	Repositório, manuscrito, material didático e relatório final	Repositório documentado + manuscrito + apresentação

8. Cronograma de execução (12 meses)

O cronograma é exequível dentro da vigência mínima de 12 meses do edital (item de avaliação 'Exequibilidade'), com marcos claros e produtos verificáveis a cada trimestre. Parte substancial da infraestrutura de software já está implementada (ver Seção 9), o que reduz o risco de execução.

Mês	Atividades principais	Produtos esperados	Meta
1	Levantamento de bases, critérios de inclusão, desenho do pipeline	Plano técnico + lista de bases	1
2	Coleta e curadoria inicial de genomas e metadados	Base preliminar curada	1
3	Padronização taxonômica, dedup, estruturação	Banco integrado v1	1
4	k-mers, embeddings genômicos, baselines	Matrizes de atributos + baselines	2
5	Implementação da JEPA genômica	Protótipo funcional	3
6	Treinamento e ajuste da JEPA genômica	Embeddings virais preliminares	3
7	Extensão vírus-hospedeiro	Modelo JEPA vírus-hospedeiro	4
8	Integração	Espaço latente multimodal	4

	ecológica/interacional exploratória	preliminar	
9	Fine-tuning supervisionado para risco	Modelo preditivo + métricas iniciais	5
10	Validação e comparação (LSTM/Transformer/k-mers)	Relatório comparativo	5
11	Interpretabilidade, ablação, UMAP/t-SNE, ranking	Figuras, rankings, interpretação	5
12	Repositório, manuscrito, relatório final	Manuscrito + repositório + relatório	6

Marcos (milestones):

- **M3** — Banco integrado v1 disponível e documentado.
- **M6** — JEPA genômica treinada com embeddings preliminares avaliados.
- **M9** — Primeiro modelo de risco de spillover com métricas.
- **M12** — Repositório público + manuscrito em preparação/submissão.

9. Resultados preliminares

O subprojeto já conta com implementação avançada e resultados preliminares que demonstram viabilidade técnica:

- **Dados:** ~59 mil sequências coletadas (13 famílias virais do NCBI + GISAID) e 26 mil após curadoria, com balanceamento por família (2.000/família).
- **Software:** pipeline completo em Python (coleta, curadoria, features, treino, avaliação, dashboard) versionado e documentado.
- **Treino:** pré-treino JEPA em GPU (NVIDIA RTX 3050) com checkpointing por época e retomada automática.

Benchmark de representações k-mer (3.000 sequências, 128 componentes PCA) — seleção baseada em desempenho e custo de memória:

k	Features	Var. explicada	AUROC (5-fold)	RAM
3	64	100%	0,9948	2 MB
4 (selecionado)	256	98,2%	0,9961	8 MB
5	1.024	87,2%	0,9961	36 MB
6	4.096	75,4%	0,9947	115 MB
7	16.384	68,3%	0,9934	451 MB

O valor $k = 4$ foi selecionado por apresentar o melhor AUROC (empatado com $k = 5$) usando 56× menos memória que $k = 7$. Notavelmente, $k = 7$ apresenta o pior AUROC — vocabulários grandes introduzem ruído em datasets deste porte. Estes baselines fortes estabelecem o piso de desempenho a ser superado pelos embeddings JEPA na predição de risco entre famílias virais (cenário mais realista para vírus emergentes).

Recursos públicos do projeto: código em github.com/gbmotta/jepa-spillover; modelos e dados em huggingface.co/gbmotta; dashboard interativo em huggingface.co/spaces/gbmotta/jepa-spillover-dashboard.

10. Infraestrutura disponível

O subprojeto é predominantemente computacional, o que reduz custos e dependências laboratoriais. A infraestrutura necessária e disponível inclui:

- **Computação local:** estação de trabalho com GPU NVIDIA (CUDA) para treino de modelos de aprendizado profundo; ambiente Linux com pilha científica Python (PyTorch, scikit-learn, pandas).
- **Dados:** acesso a bases públicas (NCBI, VirusHostDB, IntAct) e credenciamento institucional GISAID para dados genômicos virais.
- **Publicação/reprodutibilidade:** GitHub e Hugging Face Hub para versionamento, publicação de modelos/datasets e hospedagem do dashboard interativo, com rastreabilidade e ciência aberta.
- **Institucional:** infraestrutura de rede, servidores e apoio de TI do Instituto Aggeu Magalhães — Fiocruz Pernambuco; possibilidade de uso de recursos computacionais de alto desempenho da Fiocruz para etapas de maior escala.

[Complementar com detalhes específicos do laboratório/grupo: servidores, clusters, espaço físico e demais recursos disponibilizados pelo(a) supervisor(a).]

11. Contribuição do subprojeto para o grupo de pesquisa / laboratório

Além da entrega de modelos e código, o subprojeto prevê a transferência de conhecimento em inteligência artificial, deep learning e aprendizado auto-supervisionado para estudantes e membros da equipe. Esse componente formativo é um produto duradouro: mesmo que o modelo JEPA seja refinado em etapas futuras, as competências desenvolvidas permanecem na instituição e podem ser aplicadas a outros contextos. Como diferenciais concretos, o subprojeto pode incluir:

- tutoriais e material didático em português sobre JEPA aplicada à bioinformática viral;
- workshops internos sobre aprendizado auto-supervisionado, embeddings e análise de genomas com IA;
- capacitação de colaboradores de outros grupos do IAM/Fiocruz interessados em IA aplicada à saúde;
- documentação e scripts reutilizáveis como base para projetos futuros do laboratório.

Ao aplicar arquiteturas de aprendizado profundo de última geração a problemas de vigilância genômica, o subprojeto posiciona o laboratório e o Instituto Aggeu Magalhães na fronteira da bioinformática aplicada à saúde pública, fortalecendo a competitividade em editais nacionais e internacionais e abrindo portas para colaborações científicas.

12. Contribuição da formação do candidato para o projeto do(a) supervisor(a)

A formação e a expertise técnico-científica do candidato — em ciência de dados, aprendizado de máquina e desenvolvimento de software reprodutível — complementam diretamente as competências biológicas e epidemiológicas do grupo. O candidato aporta a capacidade de implementar, treinar e avaliar modelos de IA de fronteira (JEPA/Transformers), estruturar pipelines de dados escaláveis e publicar resultados de forma aberta e reprodutível. Essa integração acelera a execução do projeto do(a) supervisor(a), amplia seu alcance metodológico e cria condições para produção científica conjunta de alto impacto, submissão a novos editais e formação de recursos humanos qualificados no IAM/Fiocruz. *[Complementar com aderência específica entre a trajetória do*

candidato — titulação, publicações e experiência — e as necessidades do projeto do(a) supervisor(a).]

13. Relevância para o SUS e alinhamento com a vigilância nacional

A proposta é complementar — não concorrente — aos sistemas de vigilância consolidados no Brasil. O InfoDengue e o InfoGripe são plataformas de monitoramento epidemiológico em tempo real amplamente usadas pelo Ministério da Saúde e por secretarias estaduais, com foco em vírus já conhecidos e circulantes. O JEPA-Spillover atua na etapa anterior: identificar, entre vírus pouco caracterizados de vigilância ambiental e metagenômica, aqueles com maior potencial de se tornarem futuros alvos desses sistemas. Como colaboração futura explícita, vírus priorizados pelo ranking JEPA poderiam ser incorporados como alertas precoces ao InfoDengue/InfoGripe.

O subprojeto alinha-se às diretrizes do Ministério da Saúde e da Fiocruz para fortalecimento da vigilância genômica no contexto pós-COVID-19, e contribui para a soberania nacional em tecnologias críticas de saúde ao desenvolver soluções de IA abertas, reproduzíveis e adaptadas ao contexto brasileiro, com potencial de integração a redes como SIVEP-Gripe, CIEVS e o Sistema de Alerta e Resposta de Emergências.

14. Riscos e mitigação

Risco	Mitigação
Rótulos escassos/enviesados	Núcleo auto-supervisionado (JEPA); validação entre famílias inteiras.
Dados ecológicos incompletos	Integração incremental; componente multimodal tratado como exploratório.
Custo computacional (Transformers)	Baseline k-mer/CNN; uso de GPU quando disponível; blocos menores e checkpointing.
Vazamento de informação na avaliação	Particionamento estratificado + holdout de famílias inteiras.

15. Reprodutibilidade e ciência aberta

- configuração única e versionada (config.yaml) e seed fixa;
- ambiente declarado (environment.yml / requirements.txt);
- acompanhamento de experimentos e publicação de código, modelos e documentação em GitHub e Hugging Face Hub;
- depósito da produção textual no Repositório Institucional ARCA, em conformidade com a Política Institucional de Acesso Aberto da Fiocruz.

16. Considerações éticas e de biossegurança

O subprojeto utiliza exclusivamente sequências genômicas e metadados de bases de dados públicas e de acesso controlado (GISAID, mediante credenciamento institucional), sem coleta de material biológico novo nem dados de pacientes identificáveis, o que, em princípio, dispensa submissão ao CEP/CEUA. O uso de dados GISAID observa integralmente os termos de uso da plataforma, e as sequências não são redistribuídas. Eventuais autorizações legais aplicáveis (CEP, CEUA, SISBIO, CI-BIO, SISGEN) serão anexadas conforme o item 4.6 do edital, quando pertinentes ao projeto do(a) supervisor(a).

17. Aviso

Trata-se de ferramenta de apoio à priorização para vigilância genômica, em estágio de prova de conceito. Não substitui investigação laboratorial, sistemas de vigilância epidemiológica estabelecidos nem decisões de saúde pública. Resultados in silico exigem validação experimental.

18. Referências selecionadas

- [1] Assran, M. et al. Self-Supervised Learning from Images with a Joint-Embedding Predictive Architecture (I-JEPA). CVPR, 2023.
- [2] Bardes, A. et al. V-JEPA: Video Joint-Embedding Predictive Architecture. Meta AI, 2024.
- [3] LeCun, Y. A Path Towards Autonomous Machine Intelligence. Open Review, 2022.
- [4] Ji, Y. et al. DNABERT: pre-trained Bidirectional Encoder Representations from Transformers model for DNA-language in genome. Bioinformatics, 2021.
- [5] Dalla-Torre, H. et al. The Nucleotide Transformer: Building and Evaluating Robust Foundation Models for Human Genomics. bioRxiv, 2023.
- [6] Mizumoto, K.; Chowell, G. et al. Sistemas de vigilância e modelagem epidemiológica (InfoDengue/InfoGripe). Fiocruz.
- [7] Mihara, T. et al. Virus-Host Database (VHDB). Viruses, 2016.
- [8] ICTV. Master Species List (MSL). International Committee on Taxonomy of Viruses.